ANALISIS PENJUALAN PRODUK NIKE U.S. 2020–2021: PREDIKSI KLASIFIKASI VOLUME PENJUALAN MENGGUNAKAN LOGISTIC REGRESSION, RANDOM FOREST, DAN GRADIENT BOOSTING.

Nama: Najwa Kathrenia · NIM: 20240801221 · Program Studi: Teknik Informatika

Dosen Pengampu: DIAH ARYANI , ST, M.Kom

Ringkasan

Laporan ini menganalisis 9.360 transaksi penjualan produk Nike di Amerika Serikat periode Januari 2020 – Desember 2021 yang diperoleh dari Kaggle. Analisis mengikuti tahapan proyek data science pada dokumen acuan: menentukan objek bisnis, mengumpulkan data, menelaah dan memvalidasi data, melabeli data, membangun model, mengevaluasi model, dan menyimpan model. Tiga algoritma klasifikasi (Logistic Regression, Random Forest, Gradient Boosting) dibandingkan untuk memprediksi apakah sebuah transaksi memiliki volume penjualan tinggi (*High Sales Volume*). Akurasi data uji berturut-turut sekitar 62%, 84%, dan 83%. Gradient Boosting direkomendasikan karena paling stabil (selisih akurasi training–testing hanya sekitar 2 poin persentase).

1. Menentukan Objek Bisnis

Persaingan industri apparel dan footwear di pasar Amerika Serikat sangat ketat. Produsen seperti Nike menjual produknya melalui banyak retailer (toko fisik, outlet, dan daring) di berbagai wilayah, sehingga manajemen perlu memahami kombinasi produk, wilayah, retailer, metode penjualan, dan harga yang menghasilkan penjualan tinggi. Pemahaman ini membantu perencanaan stok, penentuan harga, dan pemilihan kanal distribusi.

Objektif bisnis: memprediksi apakah suatu transaksi akan menghasilkan volume penjualan tinggi atau rendah/normal. Targetnya dibuat biner berdasarkan nilai median kolom Units Sold: transaksi dengan Units Sold di atas median diberi label High Sales Volume (1), selebihnya Low/Normal Sales Volume (0). Model yang dibandingkan adalah Logistic Regression, Random Forest, dan Gradient Boosting.

2. Mengumpulkan Data dan Menentukan Objek Data

Dataset Nike U.S. Sales (2020–2021) diunduh dari Kaggle (https://www.kaggle.com/datasets) dalam format CSV, kemudian diunggah ke lingkungan Google Colab. Dataset terdiri dari 9.360 baris dan 9 kolom tanpa nilai kosong.

Kolom	Tipe	Keterangan
Invoice Date	object (tanggal)	Tanggal faktur, format dd-mm-yyyy
Product	kategorikal	6 kategori produk: Men's/Women's × Street Footwear

Kolom	Tipe	Keterangan
		/ Athletic Footwear / Apparel
Region	kategorikal	5 wilayah: Northeast, West, Midwest, South, Southeast
Retailer	kategorikal	6 retailer: Foot Locker, West Gear, Sports Direct, Kohl's, Amazon, Walmart
Sales Method	kategorikal	In-store, Outlet, Online
State	kategorikal	48 negara bagian AS
Price per Unit	numerik (int)	Harga per unit (USD)
Total Sales	numerik (int)	Total penjualan (USD)
Units Sold	numerik (int)	Jumlah unit terjual

Pustaka yang digunakan:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.metrics import confusion_matrix, classification_report, accuracy_score
import pickle
```

Pembacaan data dan pemeriksaan awal:

```
df_nike = pd.read_csv('/content/Nike Dataset.csv')
print("Bentuk Dataset Nike:", df_nike.shape)
display(df_nike.head())
df_nike.info()
```

Hasil: (9360, 9). Kolom Price per Unit, Total Sales, dan Units Sold bertipe int64, sedangkan enam kolom lainnya bertipe object.

3. Menelaah, Mengonstruksi, dan Memvalidasi Data

3.1 Pemeriksaan kualitas data

Pemeriksaan nilai kosong dan duplikat dilakukan sebelum pemodelan.

```
df = df_nike.copy()
print(df.isnull().sum())
print("Jumlah Duplikat:", df.duplicated().sum())
if df.duplicated().sum() > 0:
    df = df.drop_duplicates().reset_index(drop=True)
```

Hasilnya, tidak ada nilai kosong pada seluruh kolom dan tidak ada baris duplikat, sehingga seluruh 9.360 baris dapat digunakan.

3.2 Validasi format tanggal

Kolom Invoice Date berformat hari-bulan-tahun (misalnya 21-01-2020). Jika dikonversi dengan pd.to_datetime() tanpa menyebutkan format, pandas membaca nilai sebagai bulan-hari, sehingga 5.439 baris (58%) gagal dikonversi dan sebagian baris lain terbaca dengan bulan dan hari tertukar. Konversi yang benar menyebutkan format secara eksplisit, dan hasilnya seluruh 9.360 tanggal valid pada rentang 1 Januari 2020 – 31 Desember 2021.

```
# Konversi tanggal dengan format eksplisit (dd-mm-yyyy)
df_cleaned = df_nike.copy()
df_cleaned['Invoice Date'] = pd.to_datetime(df_cleaned['Invoice Date'], format='%d-%m-%Y')
print(df_cleaned['Invoice Date'].isnull().sum())   # 0

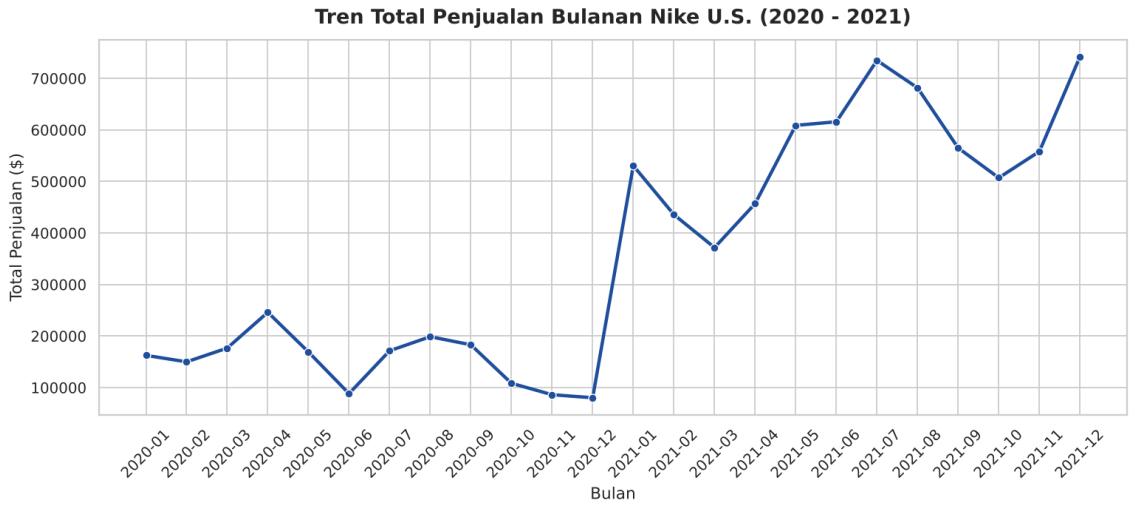
# Agregasi total penjualan per bulan
df_cleaned['Month_Period'] = df_cleaned['Invoice Date'].dt.to_period('M')
monthly_sales = df_cleaned.groupby('Month_Period')['Total Sales'].sum().reset_index()
monthly_sales['Month_Period'] = monthly_sales['Month_Period'].astype(str)

plt.figure(figsize=(12, 6))
sns.lineplot(data=monthly_sales, x='Month_Period', y='Total Sales', marker='o', linewidth=2.5)
plt.title('Tren Total Penjualan Bulanan Nike (2020 - 2021)')
plt.xticks(rotation=45)
plt.show()
```

3.3 Eksplorasi data (EDA)

Total penjualan seluruh periode mencapai sekitar USD 8,63 juta. Penjualan 2020 sebesar USD 1,82 juta dan 2021 sebesar USD 6,81 juta, atau sekitar 3,7 kali lipat. Tren bulanan pada Gambar 1 menunjukkan penjualan relatif rendah sepanjang 2020 (titik terendah Desember 2020 sebesar

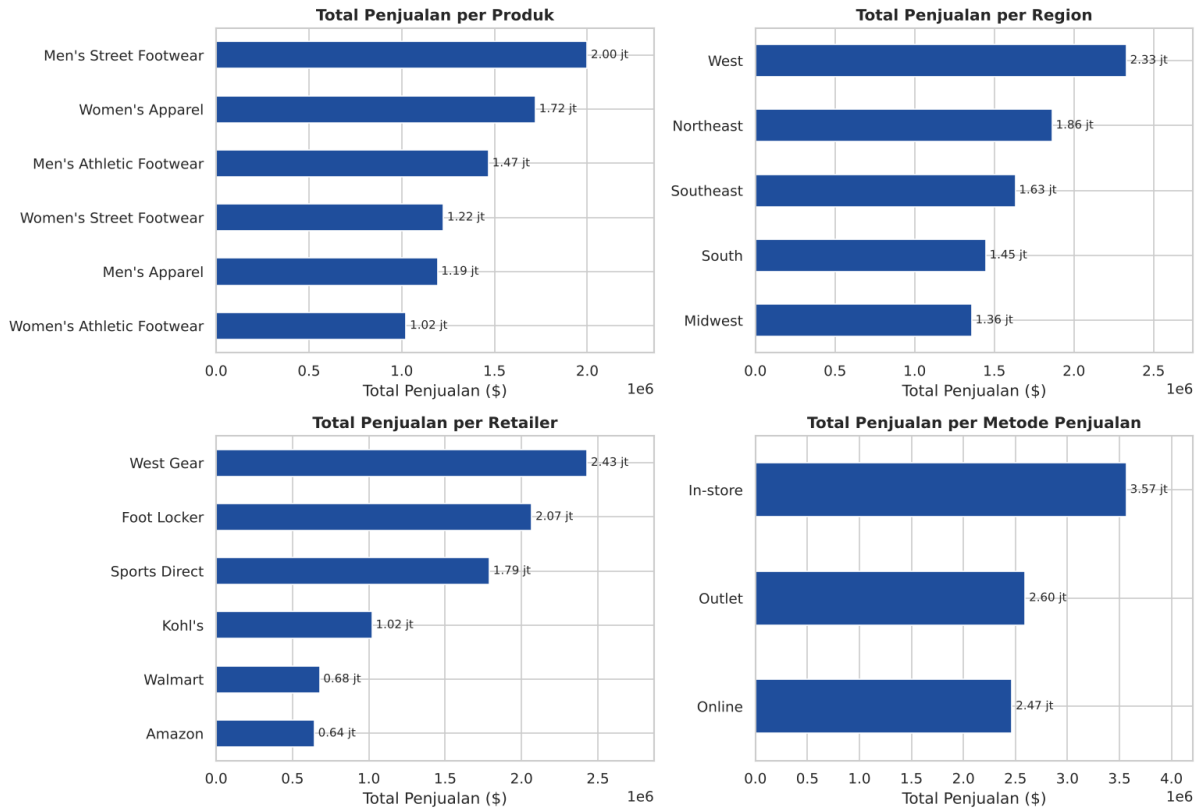
USD 80.277), naik tajam sejak awal 2021, dan mencapai puncak pada Desember 2021 sebesar USD 742.198.



Gambar 1. Tren total penjualan bulanan Nike U.S. (Januari 2020 – Desember 2021)

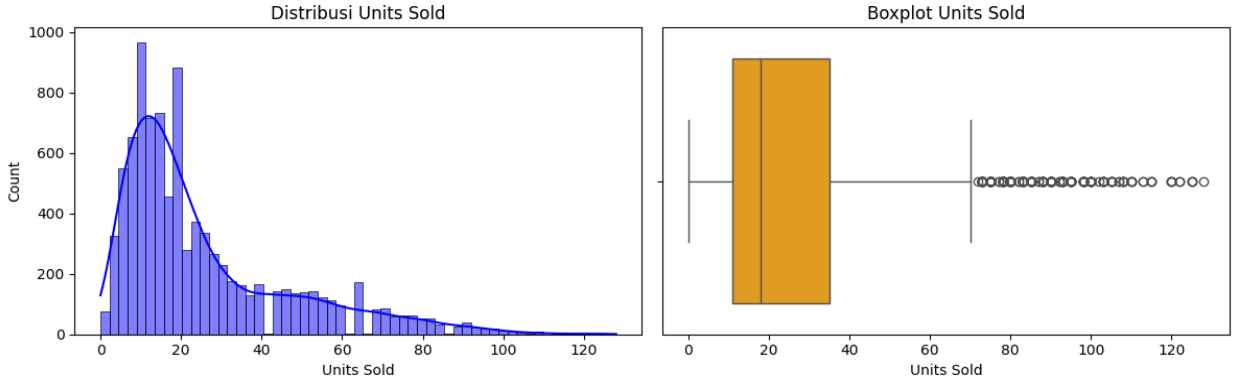
Hasil agregasi per kategori (Gambar 2) menunjukkan bahwa produk dengan penjualan tertinggi adalah *Men's Street Footwear* (USD 2,00 juta), diikuti *Women's Apparel* (USD 1,72 juta). Wilayah West memimpin (USD 2,33 juta), retailer terbesar adalah West Gear (USD 2,43 juta), dan metode In-store menghasilkan penjualan tertinggi (USD 3,57 juta) meskipun jumlah transaksi daring paling banyak.

Universitas
Esa Unggul



Gambar 2. Total penjualan per produk, region, retailer, dan metode penjualan

Distribusi variabel target, Units Sold, ditunjukkan pada Gambar 3. Distribusinya condong ke kanan (*right-skewed*): median 18 unit, rata-rata sekitar 25,9 unit, dan maksimum 128 unit. Karena itu median dipilih sebagai batas label, bukan rata-rata.



Gambar 3. Distribusi dan boxplot Units Sold

```
plt.figure(figsize=(12, 4))
plt.subplot(1, 2, 1)
sns.histplot(df['Units Sold'], kde=True, color='blue')
plt.title('Distribusi Units Sold')
```

```
plt.subplot(1, 2, 2)
sns.boxplot(x=df['Units Sold'], color='orange')
plt.title('Boxplot Units Sold')
plt.tight_layout()
plt.show()
```

Catatan validasi: hanya 1.905 dari 9.360 baris (sekitar 20%) yang nilai Total Sales-nya sama dengan Price per Unit × Units Sold. Ketidakkonsistenan ini, ditambah fakta bahwa Total Sales sangat bergantung pada Units Sold, menjadi alasan tambahan untuk tidak memakai Total Sales sebagai fitur.

4. Melakukan Label Data

Target High_Sales dibuat dari median Units Sold (18 unit). Hasil pelabelan menunjukkan kelas yang cukup seimbang: 4.841 transaksi berlabel 0 (Low/Normal) dan 4.519 transaksi berlabel 1 (High), sehingga tidak diperlukan teknik penyeimbangan kelas.

Kolom Invoice Date, Total Sales, dan Units Sold dikeluarkan dari fitur. Units Sold dibuang karena target diturunkan langsung darinya, dan Total Sales dibuang untuk mencegah kebocoran data (*data leakage*). Lima kolom kategorikal diubah menjadi numerik dengan LabelEncoder, dan setiap encoder disimpan agar data baru dapat diproses dengan cara yang sama.

```
median_units = df['Units Sold'].median()        # 18.0
df['High_Sales'] = (df['Units Sold'] > median_units).astype(int)
print(df['High_Sales'].value_counts())          # 0: 4841, 1: 4519

encoders = {}
kolom_kategori = ['Product', 'Region', 'Retailer', 'Sales Method', 'State']
df_model = df.drop(columns=['Invoice Date', 'Total Sales', 'Units Sold'])

for col in kolom_kategori:
    le = LabelEncoder()
    df_model[col] = le.fit_transform(df_model[col])
    encoders[col] = le
```

Fitur akhir yang digunakan model: Product, Region, Retailer, Sales Method, State, dan Price per Unit.

5. Membangun Model

5.1 Pemisahan data

Data dibagi menjadi 70% data latih dan 30% data uji dengan stratify=y agar proporsi kelas pada kedua set sama.

```
X = df_model.drop(columns=['High_Sales'])
y = df_model['High_Sales']
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y)
```

Hasil: X_train berukuran (6552, 6) dan X_test berukuran (2808, 6).

5.2 Logistic Regression

Model linier untuk klasifikasi biner; digunakan sebagai model dasar (*baseline*).

```
log_model = LogisticRegression(max_iter=1000).fit(X_train, y_train)
y_train_pred_log = log_model.predict(X_train)
y_test_pred_log = log_model.predict(X_test)
print(classification_report(y_test, y_test_pred_log))
```

5.3 Random Forest

Gabungan banyak pohon keputusan (*bagging*) yang mampu menangkap hubungan non-linier antar fitur.

```
rdf_model = RandomForestClassifier(random_state=42).fit(X_train, y_train)
y_train_pred_rdf = rdf_model.predict(X_train)
y_test_pred_rdf = rdf_model.predict(X_test)
print(classification_report(y_test, y_test_pred_rdf))
```

5.4 Gradient Boosting

Pohon-pohon dibangun berurutan, masing-masing memperbaiki kesalahan pohon sebelumnya (*boosting*).

```
gbt_model = GradientBoostingClassifier(random_state=42).fit(X_train, y_train)
y_train_pred_gbt = gbt_model.predict(X_train)
y_test_pred_gbt = gbt_model.predict(X_test)
print(classification_report(y_test, y_test_pred_gbt))
```

6. Evaluasi Hasil Model

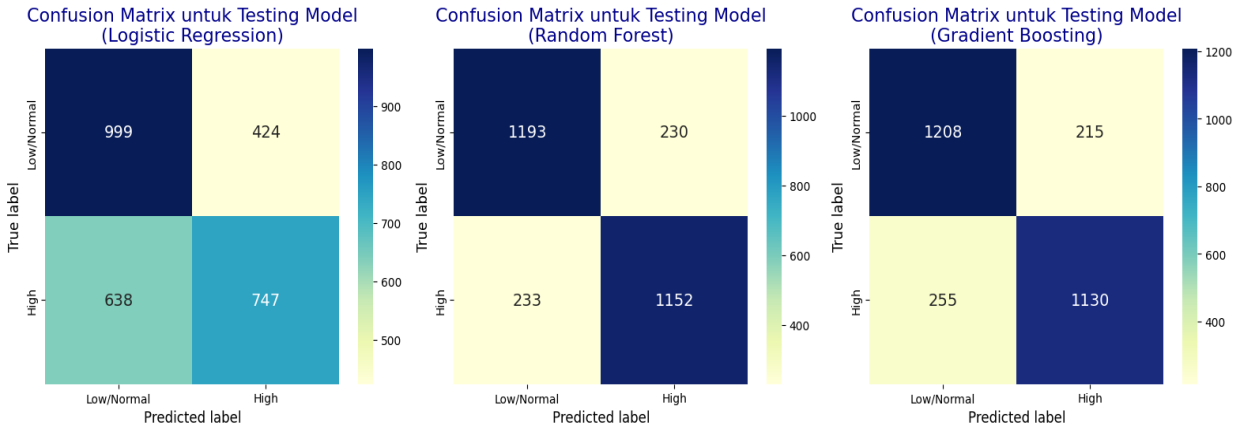
Evaluasi memakai *classification report* (precision, recall, f1-score, accuracy) dan *confusion matrix*. Dalam konteks ini, kelas positif (1) adalah *High Sales Volume*:

- True Positive (TP): transaksi diprediksi High dan memang High.
- True Negative (TN): transaksi diprediksi Low/Normal dan memang Low/Normal.
- False Positive (FP): transaksi diprediksi High, tetapi sebenarnya Low/Normal.
- False Negative (FN): transaksi diprediksi Low/Normal, tetapi sebenarnya High.

6.1 Hasil pada data uji (2.808 transaksi)

Model	Kelas	Precision	Recall	F1-score
Logistic Regression	0 (Low/Normal)	0,61	0,70	0,65
Logistic Regression	1 (High)	0,64	0,54	0,58
Random Forest	0 (Low/Normal)	0,84	0,84	0,84
Random Forest	1 (High)	0,83	0,83	0,83
Gradient Boosting	0 (Low/Normal)	0,83	0,85	0,84
Gradient Boosting	1 (High)	0,84	0,82	0,83

Confusion matrix data uji ditampilkan pada Gambar 4. Logistic Regression menghasilkan 999 TN, 424 FP, 638 FN, dan 747 TP. Random Forest menghasilkan 1.193 TN, 230 FP, 233 FN, dan 1.152 TP. Gradient Boosting menghasilkan 1.208 TN, 215 FP, 255 FN, dan 1.130 TP.



Gambar 4. Confusion matrix data uji: Logistic Regression, Random Forest, dan Gradient Boosting (kiri ke kanan)

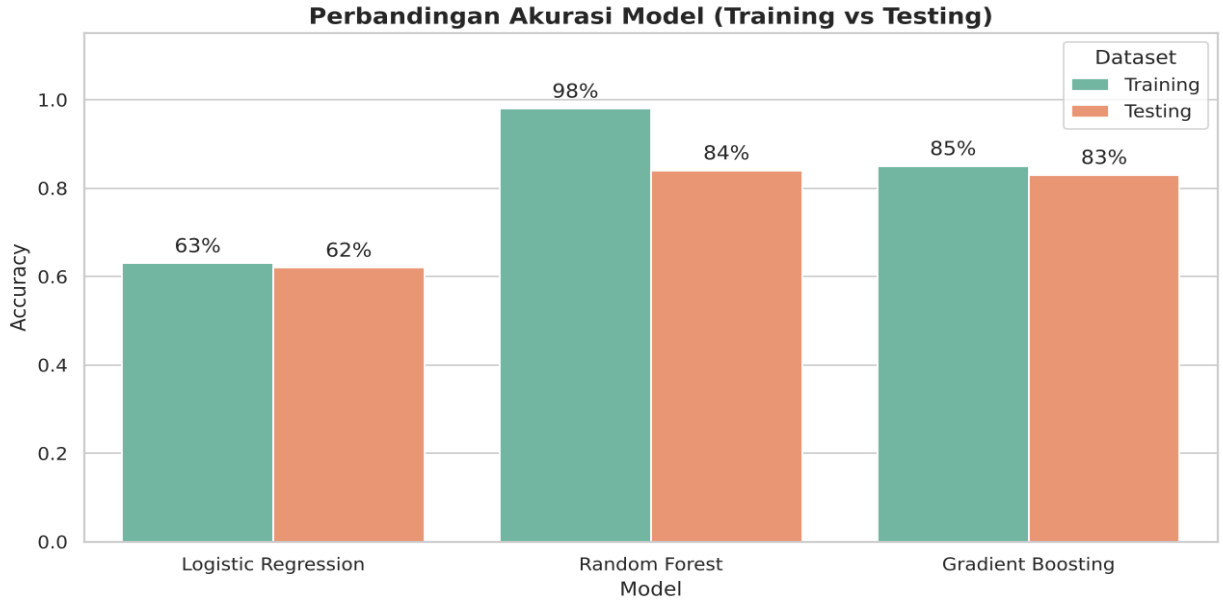
```
cm = confusion_matrix(y_test, y_test_pred_gbt)
cm_df = pd.DataFrame(cm, index=['Low/Normal', 'High'], columns=['Low/Normal', 'High'])
plt.figure(figsize=(6, 5))
sns.heatmap(cm_df, annot=True, fmt='d', cmap='YlGnBu', annot_kws={'size': 14})
plt.title('Confusion Matrix untuk Testing Model\n(Gradient Boosting)')
```

```
plt.ylabel('True label'); plt.xlabel('Predicted label')
plt.show()
```

6.2 Perbandingan akurasi

Model	Akurasi Training	Akurasi Testing	Selisih
Logistic Regression	63%	62%	1 poin
Random Forest	98%	84%	14 poin
Gradient Boosting	85%	83%	2 poin

Perbandingan visual ditunjukkan pada Gambar 5.



Gambar 5. Perbandingan akurasi training dan testing ketiga model

6.3 Analisis

- **Logistic Regression** paling rendah (akurasi uji 62%) tetapi sangat stabil. Rendahnya akurasi menunjukkan bahwa hubungan antara fitur dan volume penjualan bersifat non-linier, sehingga model linier kurang mampu menangkapnya (*underfitting*).
- **Random Forest** memiliki akurasi uji tertinggi (sekitar 84%), tetapi akurasi training mendekati sempurna (98%). Selisih 14 poin menandakan *overfitting*: model cenderung menghafal data latih.
- **Gradient Boosting** memiliki akurasi uji sekitar 83%, hanya selisih sekitar 0,2 poin persentase dari Random Forest, dengan selisih training–testing hanya sekitar 2 poin. Ini menunjukkan kemampuan generalisasi terbaik.

7. Menyimpan Model dan Menguji Data Baru

Kode pemilihan model memilih model dengan akurasi data uji tertinggi lalu menyimpannya bersama *encoder* ke best_model_nike.pkl dengan pickle.

```
scores = {
   'Logistic Regression': accuracy_score(y_test, y_test_pred_log),
   'Random Forest': accuracy_score(y_test, y_test_pred_rdf),
   'Gradient Boosting': accuracy_score(y_test, y_test_pred_gbt)
}
best_model_name = max(scores, key=scores.get)
best_model_obj = {'Logistic Regression': log_model,
                  'Random Forest': rdf_model,
                  'Gradient Boosting': gbt_model}[best_model_name]

pickle.dump({'model': best_model_obj, 'encoders': encoders},
            open('best_model_nike.pkl', 'wb'))
```

Pengujian dengan data transaksi baru dilakukan dengan memuat model, meng-encode data dengan encoder yang sama, lalu memanggil predict():

```
with open('best_model_nike.pkl', 'rb') as f:
   saved = pickle.load(f)
model, enc = saved['model'], saved['encoders']

new_data = pd.DataFrame([{
   'Product': "Men's Street Footwear", 'Region': 'Northeast',
   'Retailer': 'Foot Locker', 'Sales Method': 'In-store',
   'State': 'New York', 'Price per Unit': 55}])
for col in enc:
   new_data[col] = enc[col].transform(new_data[col])

print(model.predict(new_data), model.predict_proba(new_data))
```

Pada contoh ini model memprediksi **High Sales Volume** untuk produk *Men's Street Footwear* di Northeast melalui Foot Locker (In-store, New York, harga USD 55).

8. Kesimpulan

1. Dataset Nike U.S. 2020–2021 berisi 9.360 transaksi, bersih dari nilai kosong dan duplikat. Format tanggal harus dibaca sebagai dd-mm-yyyy agar seluruh data valid. Penjualan meningkat sekitar 3,7 kali lipat dari 2020 ke 2021.
2. Target klasifikasi *High Sales Volume* dibuat dari median Units Sold (18 unit) dan menghasilkan kelas yang seimbang.

3. Dari tiga model, Random Forest dan Gradient Boosting jauh mengungguli Logistic Regression (sekitar 83–84% berbanding 62%).
4. Random Forest unggul tipis pada akurasi uji tetapi mengalami *overfitting*. Gradient Boosting direkomendasikan karena akurasinya hampir sama dan jauh lebih stabil pada data baru.

Saran pengembangan: melakukan *hyperparameter tuning* (misalnya `max_depth` pada Random Forest), validasi silang (*cross-validation*), menambahkan fitur waktu seperti bulan dan musim, serta mengevaluasi pemakaian *one-hot encoding* untuk fitur kategorikal.

Daftar Pustaka

- Kaggle. *Nike U.S. Sales Dataset (2020–2021)*. https://www.kaggle.com/code/hamizanhibatullah407/analisis-penjualan-produk-nike-u-s-2020-2021 Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Dokumen acuan: Tugas Akhir Diah Aryani, *Customer Churn Prediction* (Sertifikasi Kompetensi Okupasi Associate Data Science).
- Tautan Tugas:
    1. Google Drive: https://drive.google.com/drive/folders/1I-3ZZ49jvf_E7ClHeq50-HokmVDPI4-n
    2. Github: https://github.com/Najwakathh/Analisis-Penjualan-Produk-Nike-U.S.-2020---2021---UTS-Kapita-Selekta-Informatika

Universitas Esa Unggul